CS4641A1 - 王本然楷 - 郭宗敏等

Yelp 评论分析：从 Baseline 到商业智能 Agent

一个团队与 AI 协作实践，从特征工程演进至 Agentic RAG 系统

GitHub: github.com/YuhanWang25/Yelp-Project

项目概览

本项目对 Yelp 评论数据（大型文本）构建了一个四阶段的工程实践：从简单基线出发，每一阶段优势一目了然，最终实现一个能回答业务问题并给出可执行建议的商业智能系统。四阶段分别是分类任务的特征工程与优化、聊天机器人、RAG 系统、模型微调与模式识别实践。

第一周	第二周	第三周	第四周
Baseline 搭建	RAFT 微调	大规模实验	模型微调
TF-IDF + Logistic Regression	Llama 3.1 8B + LoRA	多模型对比	Llama 3.1 8B + LoRA 超参数调优
建立性能基线	聊天机器人	特征工程 vs 模型	模式识别
	RAG 系统	数据质量	Agentic RAG 工具调用

核心洞察：特征工程一致带来性能提升，但模型选择带来质的飞跃。RAG 系统提供可解释性，Agentic RAG 实现商业价值。

第一周 — Baseline 对比

在 5 分类任务上，对比三种建模方式的表现：（测试集规模）。

方法	准确率	Accuracy	Macro F1
TF-IDF + Logistic Regression	54.92%	54.92%	54.92%
DistilBERT fine-tuned	59.23%	52.89%	52.89%
RAFT（微调）	**62.50%**	**62.50%**	

为什么 Baseline 对比？

- 为什么 TF-IDF？ 经典文本分类基线，快速实现，可解释性强（查看特征权重）
- 为什么 DistilBERT？ 预训练语言模型，通用文本理解能力强，但未针对领域优化
- 为什么 Llama 3.1 8B？ 指令跟随能力强，支持 JSON 结构化输出，适合生成可执行建议
- 为什么 Llama 3.1 8B 作为 RAFT 基模型？ 平衡性能与成本，支持 LoRA 高效微调，适合迭代实验

第二周 — RAFT 微调实验

在以下四种数据形式中微调模型，评估哪种输出结构能提升模型表现：

维度	选项
Backbone 模型	meta-llama/Meta-Llama-3.1-8B-Instruct，Qwen/Qwen2.5-7B-Instruct
任务定义	二分类（2-class）、3 分类、5 分类
训练模式	Classification（交叉熵）、Regression（MSE）
学习率	1e-5、2e-5
Batch size	4、8、16
训练轮数（Epochs）	3、4
总组合数	**3 × 3 × 2 × 2 × 2 × 2 = 216**

每组实验记录指标：准确率 (Accuracy)、分类报告 (classification_report)、confusion matrix 及 predictions 文件。由于资源有限，采用分层抽样子集进行快速迭代 (checkpoint)，完整训练保留最优配置。最终 5 分类配置：学习率 2e-5，batch size 8，3 个 epoch，使用 bfloat16 精度。

二分类 — 测试集

模型	准确率 Accuracy	宏平均 Macro F1	AUC
DistilBERT fine-tuned	96.54%	96.53%	—
RAFT fine-tuned	97.07%	97.06%	—
RoBERTa-base	**97.62%**	**97.61%**	**0.9968**

5 分类 — 测试集

模型	准确率 Accuracy	宏平均 Macro F1	Off-by-1 容错率
DistilBERT fine-tuned	63.4%	63.36%	97.5%
RAFT fine-tuned	68.75%	68.36%	97.49%
RoBERTa-base	**68.56%**	**68.49%**	**98.19%**

为什么 F1 指标（宏平均）重要？ 宏平均对每个类别赋予相同权重，即模型同时需要在每个类别上表现好。二分类 F1 接近饱和（96+），5 分类 F1 仍有 20 个百分点的提升空间，说明任务难度随类别数增加显著上升。

为什么 Off-by-1 容错率？ 评估模型是否“接近正确”。即使预测错误，若预测结果与真实标签相差 1 个等级，仍可接受。这在实际应用中具有业务价值，例如将 4 星评论预测为 3 星，用户体验影响较小。

为什为 RoBERTa 胜于 RAFT 和 DistilBERT？ RoBERTa 在预训练阶段采用了 NLP 任务优化：动态掩码、移除 NSP 目标、更大的 batch size。这些改进使其在文本理解任务上成绩优于通用模型。RAFT 虽采用 Llama 3.1 8B 等更大模型，但在本任务上表现不佳，可能原因：指令跟随能力对分类任务帮助有限，模型参数量过大导致过拟合风险。

为什为 LoRA 秩 r 和 alpha 一致最好？ 实验对比 r=16, alpha=16 与 r=16, alpha=32，发现前者表现更优。这表明在 LoRA 微调中，保持缩放因子 alpha/r = 1 通常是稳定且有效的选择。过大的 alpha 可能导致梯度爆炸或训练不稳定。

最终配置（5 分类）： RoBERTa-base，学习率 2e-5，batch size 8，3 个 epoch，使用 bfloat16 精度。这组配置在准确率、宏平均 F1 和 Off-by-1 容错率三个指标上均表现最优，是生产环境部署的推荐配置。

第三部分 — 大规模数据评测与诊断

对两个指令跟随模型，在同一评估协议下，测试其泛化能力与鲁棒性。

	Qwen2.5-7B-Instruct	Llama-3.1-8B-Instruct
第一轮	单一任务，零样本直接推理	→ 第一轮：零样本直接推理
		→ 第二轮：JSON 格式（Guided）强制
第二轮	LoRA 微调（Guided）SFT	→ 第三轮：流式数据加载（Fixed）
		→ 第四轮：LoRA 微调 + 早期停止机制

模型配置详情

Qwen2.5-7B-Instruct — 两种解码策略

参数	Greedy（确定性）	Sampling（创造性）
目标	稳定、可复现的结果	多样性、探索性输出
温度	0（始终选最高概率token）	0.7（平衡随机性与质量）
top_p	1.0（禁用）	0.9（核采样）
最大输出长度	512 tokens	512 tokens
结构化输出	通过 JSON 模式强制	通过 JSON 模式强制

Llama-3.1-8B-Instruct — 三轮迭代优化

轮次	改进	目的
第一轮	零样本直接推理	建立基线，测试模型开箱即用能力
第二轮	JSON 模式（Guided）强制输出	减少解析失败，提高结构化输出稳定性
第三轮	流式数据加载（Fixed）	解决大数据集内存溢出问题，支持全量评测
第四轮	LoRA 微调 + 早期停止机制	通过领域适应提升分类准确率，防止过拟合

为什么选择 Qwen2.5-7B 作为单一模型？ 指令跟随能力强，支持 JSON 模式保证输出格式，适合生产环境。

为什么 Llama 3.1 8B 需要三轮？ 基模指令跟随能力较弱，需要通过 JSON 模式强制结构化输出，再通过微调提升分类准确率。

为什么 Greedy 解码？ 评估任务要求可复现性，temperature=0 确保每次运行结果一致。

为什么 Sampling 参数？ 虽未用于评估，但保留配置以备后续探索多样性输出的场景。

为什么流式数据加载？ 三个数据集合计约 1.5 万条，一次性加载可能内存不足。流式加载保证大数据集可运行。

为什么早期停止？ 防止模型在小数据集上过拟合，保留验证集表现最优的 checkpoint。

评测指标

指标	说明
任务成功率	模型输出结果格式正确的比例
方面分析	能够识别餐厅评论中提及的方面（如：食物、服务、环境）
幻觉率	模型编造输入中不存在的信息的比例
推理质量	解释是否合理、是否以证据支持结论

评测数据

数据集	规模	用途
第一轮	500 条	快速迭代
第二轮	5,000 条（分层抽样）	稳定性评估
第三轮	全量（约 1.5 万条）	生产级评估

结构化输出实现

- **Qwen 模型**：通过 vLLM 的 `guided_decoding` 参数，强制输出符合 JSON 模式
- **Llama 模型**：通过 Unsloth 的 `FastLanguageModel.for_inference()` 优化推理速度，支持 JSON 模式

关键发现

- 模型规模不等于效果：Llama 3.1 8B 经过三轮迭代后，在结构化输出稳定性上接近 Qwen 7B
- 微调是最有效的杠杆：LoRA 微调带来的分类准确率提升，通常超过提示词工程的收益
- 评测先行：没有评测集，任何改进都是盲目的

聊天机器人

- **RAG 基础设施**：Chunk 级 FAISS 索引，高重叠切片策略，基于证据的回答生成
- **LangGraph Agent 架构**：ReAct 模式，工具调用（`search_reviews`、`get_business_details`）
- **混合检索实现**：语义相似度 + 关键词匹配，支持多维度过滤（城市、类别、最低评分）
- **结构化证据输出**：引用证据的回答，区分事实陈述与推理
- **多轮对话管理**：支持上下文追踪，处理指代消除（“那个”、“刚才说的”）
- **可交互 Demo**：Gradio 界面，支持 10 个预设问题，实时显示工具调用过程和检索结果
- **系统级 RAG 实验**：216 组超参数搜索，系统化记录实验结果（第二周）

模型微调实验

- **RAFT 微调实验**：在 Llama 3.1 8B 上对比 4 种输出结构，评估哪种结构能提升模型表现
- **LoRA 参数对比**：r=16 vs r=32，alpha 缩放因子的影响
- **模式识别**：从评论中提取可复用的业务洞察（如：“周末需要提前预约”）

评测与诊断

- **多维度评测**：准确率、宏平均 F1、Off-by-1 容错率、幻觉率、推理质量
- **失败模式分析**：按类别、长度、置信度分桶，定位模型薄弱环节
- **实验可追溯**：每次实验保存配置、日志、checkpoint，支持复现与对比

工程实践

- **模块化设计**：数据、模型、评测、工具解耦，支持独立迭代
- **生产级考虑**：流式处理、checkpoint 恢复、错误处理、日志记录
- **文档先行**：每个阶段先写设计文档，再实现，保证可解释性

关键结论

- 特征工程带来稳定提升，但模型选择带来质的飞跃
- 小模型 + 好工程 > 大模型 + 坏工程
- 结构化输出是 RAG 可靠性的关键
- 评测先行，没有评测集的改进都是盲目的

技术栈

- **模型**：Qwen2.5-7B-Instruct、Llama 3.1 8B、RoBERTa-base
- **微调**：LoRA、PEFT、Unsloth
- **推理**：vLLM、Transformers
- **检索**：FAISS、sentence-transformers
- **Agent**：LangGraph、langchain-ollama
- **工具**：Gradio、Kaggle Notebooks

项目结构

```
project_root/
├── data_processing/      # 数据清洗、采样、分层抽样
├── baseline/             # TF-IDF、DistilBERT 基线
├── llm_finetuning/       # RAFT 微调实验
├── rag/                  # RAG 检索与问答
├── agent/                # LangGraph 工具定义
├── evaluation/           # 评测指标、失败分析
└── notebooks/            # 实验记录、可视化
```

数据集

- Yelp Open Dataset：商家、评论、用户数据
- 分层抽样：按城市、类别、评分保证代表性
- 时间切分：训练集早于测试集，模拟真实部署场景

工程实践

- 实验可追溯：每次实验保存配置、日志、checkpoint
- 失败模式分析：按类别、长度、置信度分桶，定位薄弱环节
- 成本意识：记录 token 消耗、推理时间、显存占用

未来方向

- 多 agent 协作：专家 agent 处理特定方面，协调 agent 汇总
- 在线学习：从用户反馈中持续改进
- 生产部署：模型量化、推理加速、监控告警

团队

王本然楷 · 郭宗敏等

CS4641A1 · 王本然楷 · 郭宗敏等