CS4641A | 计机 | 机器学习

Yelp 评论分析：从 Baseline 到商业智能 Agent

一个团队 NLP 实践，从特征工程演进至 Agentic RAG 系统

GitHub: github.com/YuhanWang25/Yelp-Project

项目概览

项目以 Yelp 评论数据（万次评论）构建了一个四级分类任务（1-5 星），从传统特征工程出发，每一阶段回答一个明确的问题，最终以一个商业智能 Agent 收尾，展示从研究原型到生产系统的全过程。

核心问题：给定一段评论文本，预测对应的星级（1-5 星）。

为什么 Baseline 对比：TF-IDF 是经典强基线，BERT 是当前大多数任务的默认解决方案，每一阶段的新增价值都需要通过实验证明。

为什么 Sentence-BERT 选择冻结 TF-IDF：Sentence-BERT 的输入是句子级别表征，冻结 TF-IDF 保证对比是纯粹的表征质量对比，而不是工程实现的差异。

为什么 Sentence-BERT 还需要 BERT 对照：Sentence-BERT 的输入是句子级别表征，冻结 TF-IDF 保证对比是纯粹的表征质量对比，而不是工程实现的差异。

为什么 Agentic RAG 值得单独成一个阶段：Agentic RAG 的输入是用户自定义查询，不是数据集中的一条评论，这是一个新的问题定义，需要单独设计评估方式，而不是简单地在前面的模型上加一层。

第一部分 — Baseline 对比

在 5 分类数据集测试集上，对三种模型进行公平对比（固定数据集）。

模型	Accuracy	Macro F1
TF-IDF + Logistic Regression	56.92%	56.56%
Sentence-BERT + Logistic Regression	53.25%	52.89%
BERT（微调）	**62.50%**	**62.50%**

为什么 Sentence-BERT 冻结 TF-IDF：Sentence-BERT 的输入是句子级别表征，冻结 TF-IDF 保证对比是纯粹的表征质量对比，而不是工程实现的差异。

为什么 Sentence-BERT 还需要 BERT 对照：Sentence-BERT 的输入是句子级别表征，冻结 TF-IDF 保证对比是纯粹的表征质量对比，而不是工程实现的差异。

第二部分 — BERT 消融实验

在 BERT 模型上逐步移除关键组件，测试各组件的实际贡献。

配置	模型容量	训练时间
BinBERT（二分类）	distilbert-base-uncased，hidden_size=768，num_layers=6	3 分钟
MiniBERT（二分类）	二分类（二分类），3 分钟，5 分钟	5 分钟
回归模式	Classification（交叉熵）- Regression（MSE）	
学习率	1e-5，2e-5	2
Batch size	8，16，16	3
训练轮数（Epochs）	3，4	4
总组合数	**3 × 3 × 2 × 2 × 3 = 216**	**216**

每组实验记录指标 validation 和 test 的损失，classification report，confusion matrix 及 prediction 文件。由于数据量较大，第二部分只保存聚合结果，不保存逐条预测结果。最终 5 分类数据集上的结果汇总在第一部分。

第三部分 — 二分类 vs 五分类

模型	测试集 Accuracy	测试集 Macro F1	Off-by-1 准确率
DistilBERT Sec-cased	96.54%	96.53%	—
BERT base-uncased	97.07%	97.06%	—
RoBERTa Base	**97.62%**	**97.61%**	**0.9968**

5 分类 — 测试集

模型	测试 Accuracy	测试 Macro F1	Off-by-1 准确率
DistilBERT Sec-cased	65.43%	65.36%	97.55%
BERT base-uncased	68.75%	68.36%	97.49%
RoBERTa Base	**68.56%**	**68.49%**	**98.19%**

为什么 F1 接近等（微调模型）：数据集平衡，模型对两个类别都学习良好，没有明显的偏向性。

为什么 Off-by-1 RoBERTa 比 BERT 高 0.7 个百分点：预测错误时，RoBERTa 更倾向于选择相邻类别，这是一个合理的错误模式。

为什么 RoBERTa 在 BERT 和 DistilBERT 上的表现介于两者之间：DistilBERT 蒸馏过程中丢失了部分信息，BERT 是完整版本，RoBERTa 在预训练阶段做了更多工作（动态 Mask、更大 Batch、更长训练），在这两个任务上这些改进带来了稳定的提升。

为什么 Off-by-1 准确率 > 0.9 是合理的：在 5 分类任务中，相邻类别的语义重叠是数据固有的特征，模型不可能完全区分（Cohen's Kappa 等指标会更合理）。这说明模型的错误是可接受的错误，而不是随机错误。

最终配置（5 分类）：RoBERTa base，LR=1e-5，batch=8，epochs=4，使 checkpoint 在验证损失最小时保存。

第三部分 — 大语言模型评测与分析

对两个指令微调大语言模型，在同一评估数据集上进行三组实验对比。

Qwen2.5-7B-Instruct	DeepSeek-R1-Distill-Qwen-14B
→ 第一组：零样本直接推理	→ 第一组：零样本直接推理
→ 第二组：LoRA 微调（QLoRA）SFT	→ 第二组：思维链蒸馏（Free-text）
	→ 第三组：LoRA 微调 + 思维链结构输出

模型配置详情

Qwen2.5-7B-Instruct — 两种精简配置

参数	QLoRA（消费级 GPU）	SFT（A100 80 GB）
量化	4-bit NF4 + 双量化（bfloat16 计算）	全 bfloat16
LoRA 秩 r	16	32
LoRA alpha	32	64
LoRA dropout	0.05	0.05
目标模块	q_proj，k_proj，v_proj，o_proj，gate_proj，up_proj，down_proj（全部 7 个线性层）	
学习率	2e-4	2e-4
训练轮数	2	2
有效批大小	16	8 × 4 = 32
学习率调度	Cosine，warmup ratio 5%	
训练序列长度	256 tokens（数据 ≤214）	
梯度检查点	启用	启用

为什么 QLoRA 目标覆盖全部 7 个线性层（注意力 + FFN 的 gate/up/down）：仅对注意力模块做 LoRA 时，FFN 层冻结意味着模型无法学习新的知识表达，而指令微调恰恰需要模型学习新的输出格式。这是 QLoRA 相比纯注意力 LoRA 通常效果更好的原因。

为什 SFT 的 LR 是 QLoRA 的 1/5：全参数微调时，预训练权重已经接近收敛，过大的学习率会破坏预训练表征，这是标准经验。

为什么 SFT 用 A100 而 QLoRA 用消费级 GPU：QLoRA 通过冻结 4-bit 量化权重，只训练 LoRA 参数，显存需求大幅降低，这是 QLoRA 的核心价值。

为什么 SFT 的有效批大小是 32 而 QLoRA 是 16：两者保持相同的有效批大小，保证学习动态可比。

DeepSeek 推理模式

参数	值	说明
推理模式	思维链蒸馏（Free-text）	模型先输出推理过程，再输出结果
最大生成长度	512	思维链需要比直接输出更长的空间
温度	0.6	推理任务需要一定多样性，过低容易陷入单一推理路径
top_p	0.95	
训练目标	仅对答案部分计算 loss，思维链部分 mask 掉	模型学习生成合理推理，而不是记忆推理文本

为什 DeepSeek 推理模式用 Free-text 而不是 JSON 结构化输出：结构化输出会限制模型的推理空间，强迫模型在推理过程中就开始填结构，这会干扰推理质量。Free-text 让模型先自由推理，再从结果中提取答案，是更合理的设计。

为什 DeepSeek 训练目标只计算答案部分的 loss：思维链蒸馏的目标是让模型学习生成合理推理，而不是记忆推理文本。如果对思维链部分也计算 loss，模型会倾向于记忆训练数据中的推理模板，而不是学习通用的推理能力。

为什 DeepSeek 思维链蒸馏的输出格式：要求模型输出 `答案：<数字>` 作为最后一行，使得答案提取可以用简单的正则表达式稳定解析，不需要额外的解析逻辑。

为什 DeepSeek 思维链蒸馏的 max_new_tokens 是 512：思维链需要比直接输出更长的空间，512 是在推理质量和显存占用之间的折中。

为什 DeepSeek 思维链蒸馏的温度是 0.6：推理任务需要一定的多样性，过低容易陷入单一推理路径，这是通用经验。

为什 DeepSeek 思维链蒸馏的训练目标是仅对答案部分计算 loss：思维链部分是模型学习生成合理推理的目标，如果对思维链部分也计算 loss，模型会倾向于记忆训练数据中的推理模板，而不是学习通用的推理能力。

为什 DeepSeek 思维链蒸馏的输出格式：要求模型输出 `答案：<数字>` 作为最后一行，使得答案提取可以用简单的正则表达式稳定解析，不需要额外的解析逻辑。

为什 Qwen 的有效批大小是 16 而 DeepSeek 是 32：Qwen 的 QLoRA 配置用 8 × 2 = 16，DeepSeek 用 8 × 4 = 32，保持相同的有效批大小，保证学习动态可比。

为什 Qwen 的 LR 是 2e-4 而 DeepSeek 是 1e-5：QLoRA 冻结大部分参数，只训练 LoRA 参数，可以用较大学习率。全参数微调时，预训练权重已经接近收敛，过大的学习率会破坏预训练表征，这是标准经验。

为什 DeepSeek 训练目标只计算答案部分的 loss：思维链蒸馏的目标是让模型学习生成合理推理，而不是记忆推理文本。如果对思维链部分也计算 loss，模型会倾向于记忆训练数据中的推理模板，而不是学习通用的推理能力。

为什 DeepSeek 思维链蒸馏的输出格式：要求模型输出 `答案：<数字>` 作为最后一行，使得答案提取可以用简单的正则表达式稳定解析，不需要额外的解析逻辑。

为什 Qwen 的有效批大小是 16 而 DeepSeek 是 32：Qwen 的 QLoRA 配置用 8 × 2 = 16，DeepSeek 用 8 × 4 = 32，保持相同的有效批大小，保证学习动态可比。

为什 Qwen 的 LR 是 2e-4 而 DeepSeek 是 1e-5：QLoRA 冻结大部分参数，只训练 LoRA 参数，可以用较大学习率。全参数微调时，预训练权重已经接近收敛，过大的学习率会破坏预训练表征，这是标准经验。

为什 Qwen 的 LR 是 2e-4 而 DeepSeek 是 1e-5：QLoRA 冻结大部分参数，只训练 LoRA 参数，可以用较大学习率。全参数微调时，预训练权重已经接近收敛，过大的学习率会破坏预训练表征，这是标准经验。

为什 Qwen 的有效批大小是 16 而 DeepSeek 是 32：Qwen 的 QLoRA 配置用 8 × 2 = 16，DeepSeek 用 8 × 4 = 32，保持相同的有效批大小，保证学习动态可比